Propuesta de Diseño Integral

Asistente Multimodal para la Enseñanza Personalizada de la Lectoescritura

Concurso Público de Precios — Centro Ceibal
Horas de desarrollo, consultoría e investigación en IA

VFG Group — Abril 2026
Documento confidencial

1. Visión de la Solución

1.1 El problema pedagógico

La meseta en lectoescritura que enfrentan los estudiantes de 3.º a 6.º (8-12 años) no es un déficit de contenido sino de andamiaje: los docentes no pueden personalizar la retroalimentación para 25-30 alumnos simultáneamente, y las herramientas de IA convencionales agravan el problema al generar dependencia cognitiva en lugar de autonomía.

La investigación académica reciente es contundente: los tutores de IA que dan respuestas directas producen una «muleta cognitiva» que colapsa cuando el sistema se retira. En cambio, los tutores socráticos (que guían mediante preguntas y nunca revelan la respuesta) mantienen las ganancias de aprendizaje incluso después de retirar la IA (Kestin et al., Harvard/Cornell 2025; Wharton 2025).

1.2 Nuestra tesis: IA Socrática + Knowledge Tracing

Proponemos un copiloto pedagógico cuyo principio rector es «enseñar a pensar, no a responder». Cada interacción, ya sea sobre un texto escrito a mano o una lectura en voz alta, se canaliza a través de un tutor socrático que formula preguntas de andamiaje, no correcciones terminales. La fundamentación pedagógica:

- **Agencia epistémica:** el estudiante construye su propio conocimiento mediante la reflexión guiada, no la recepción pasiva de correcciones.
- **Preservación del aprendizaje:** estudios controlados demuestran que el método socrático mantiene las ganancias post-intervención, a diferencia de la IA transaccional.
- **Knowledge Tracing adaptativo:** un grafo de conocimiento por estudiante (Student Knowledge Graph) reemplaza los historiales de chat infinitos, permitiendo personalizar con precisión quirúrgica el nivel de dificultad, el tono y la densidad de pistas.

1.3 Diferenciador ético

La solución no es «solo otra IA educativa». Es un antídoto explícito contra la dependencia cognitiva que generan las herramientas conversacionales estándar. Los guardrails no son restricciones técnicas de seguridad: son el corazón del valor pedagógico del producto.

2. Arquitectura del Sistema

2.1 Arquitectura de alto nivel

La solución se estructura en tres capas desacopladas comunicadas mediante gRPC (protobuf binario, HTTP/2, streaming nativo):

Capa Frontend: aplicación web responsive (React) que presenta las interfaces diferenciadas por rol (estudiante, docente, dirección/inspección). Nunca interactúa directamente con la capa de IA.

Capa Backend: API principal (Node.js/Python) que gestiona autenticación, autorización, persistencia en MySQL 8.0+ y orquesta las llamadas a la capa de IA. Almacena el estado canónico del usuario.

Capa de IA: microservicio Python (FastAPI + gRPC) que contiene los modelos, el pipeline multi-agente, el Knowledge Tracing engine y el grafo de conocimiento en Neo4j. Es el único componente que escribe en Neo4j.

[PLACEHOLDER: Diagrama de arquitectura de alto nivel: Frontend → Backend (MySQL, S3/MinIO) → AI Layer (Neo4j, LLM APIs)]

2.2 Tres sistemas

La capa de IA opera tres subsistemas con responsabilidades claramente separadas:

Sistema	Tipo	Función
Sistema 1: Generación de Ejercicios	Batch offline	Pipeline que genera variaciones de ejercicios a partir de preguntas semilla creadas por educadores. Usa LLM (Claude Sonnet) con restricciones de catálogo de assets pre-existentes.
Sistema 2: Selección Adaptativa	Runtime	Motor de Knowledge Tracing que consulta el Student Knowledge Graph en Neo4j para seleccionar el ejercicio óptimo según el estado cognitivo actual del estudiante.
Sistema 3: Tutoría Socrática	Live streaming	Pipeline multi-agente de 5 etapas para la interacción conversacional en tiempo real con el estudiante.

2.3 Pipeline multi-agente (Sistema 3)

Cada mensaje del estudiante atraviesa una cadena de 5 agentes especializados, diseñada para garantizar que ninguna respuesta viole el principio socrático:

Etapa	Agente	Responsabilidad
1	Guardrail Pre	Filtra contenido inapropiado, detecta intentos de extraer respuestas directas, aplica el marco CARE.
2	Tutor Socrático	Genera la respuesta pedagógica usando el Student KG como contexto. Nunca revela la respuesta; formula preguntas de andamiaje.
3	Guardrail Post	Verifica que la respuesta generada no contenga la respuesta directa, datos personales ni alucinaciones fácticas.

4	Assessment Agent	Evalúa la calidad del razonamiento del estudiante y calcula el delta de actualización para los nodos del KG.
5	KG Update	Actualiza los pesos de los nodos StudentConcept/StudentSkill en Neo4j.

[PLACEHOLDER: Diagrama de secuencia: flujo de un mensaje del estudiante a través del pipeline de 5 agentes]

2.4 Grafo de conocimiento curricular (KG-RAG)

A diferencia de un RAG semántico tradicional que fragmenta documentos planos, implementamos un Knowledge Graph-enhanced RAG (KG-RAG) donde:

- Cada nodo representa una habilidad, competencia u objeto de conocimiento del currículo.
- Las aristas codifican relaciones pedagógicas explícitas: «es prerrequisito de», «es subcomponente de», «se aplica en».
- Cuando el sistema activa un tema, recorre el grafo para cargar en el contexto del LLM todo el andamiaje conceptual subyacente, dotando al tutor de precisión pedagógica absoluta.

Estudios controlados documentan mejoras de hasta 35% en evaluaciones con KG-RAG vs. recuperación semántica tradicional (arXiv:2311.17696).

2.5 Student Knowledge Graph

Cada estudiante tiene un grafo personal almacenado en Neo4j donde cada nodo (StudentConcept, StudentSkill) posee un peso probabilístico en el rango [-8, +8]:

- -8 = comprensión deficiente, confusión profunda, error crítico.
- +8 = dominio absoluto, fluidez metacognitiva.

Este grafo se consulta en tiempo real para calibrar: nivel de dificultad del siguiente ejercicio, tono del andamiaje instruccional y densidad de las pistas. La ventaja crítica de escalabilidad: elimina la necesidad de almacenar y procesar meses de historial conversacional. En lugar de procesar texto, se consulta el estado comprimido del grafo.

Los nodos usan NODE KEY compuesto (user_id, skill_code) para garantizar unicidad sin colisiones a escala.

3. Integración con el Ecosistema Ceibal

3.1 Single Sign-On (CAS)

La solución se integra con el proveedor de identidad de Ceibal mediante protocolo CAS (Central Authentication Service):

- El frontend redirige al usuario al endpoint CAS de Ceibal para autenticación.
- Tras validación exitosa, Ceibal retorna un service ticket que el backend valida contra el endpoint /serviceValidate.
- El backend emite un JWT de sesión con los claims de rol (estudiante, docente, director, inspector) extraídos del directorio de Ceibal.
- Ningún componente de la capa de IA accede a datos de identidad directos: recibe solo user_id pseudonimizado.

En el prototipo, esta integración está simulada con usuarios hardcodeados, pero la arquitectura del backend ya prevé el middleware CAS como punto único de autenticación.

3.2 Embebido en LMS vía LTI

Para que la herramienta funcione como un componente nativo dentro del LMS de Ceibal, implementamos el estándar LTI 1.3 (Learning Tools Interoperability):

- El LMS de Ceibal actúa como Platform; nuestra solución actúa como Tool.
- El flujo de lanzamiento usa OpenID Connect + OAuth 2.0 para establecer confianza.
- Recibimos el contexto LTI (curso, actividad, rol) que mapea automáticamente al año escolar y la actividad asignada por el docente.
- LTI Assignment and Grade Services (AGS) permite devolver calificaciones y métricas al gradebook del LMS.
- Deep Linking permite al docente insertar actividades específicas (lectura asignada, ejercicio de escritura) directamente desde el LMS.

3.3 Arquitectura multiactor (roles y permisos)

Rol	Acceso	Funcionalidad principal
Estudiante	Solo sus propias actividades y feedback	Subir fotos/audios, interactuar con el tutor socrático, ver su progreso.
Docente	Sus grupos/clases asignados	Vista de corrección, panel resumen de fluidez, asignación de actividades, diagnósticos individuales.
Director/a	Agregados a nivel escuela	Dashboards de métricas por grupo, alertas de estudiantes en riesgo, informes descargables.
Inspector/a	Agregados a nivel distrito/zona	Métricas comparativas entre escuelas, tendencias longitudinales, exportación para investigación.

4. Flujo de Datos

4.1 Historia A: Producción escrita

1. El estudiante toma una foto del borrador manuscrito y la sube desde la interfaz.

2. El frontend envía la imagen al backend, que la almacena en S3/MinIO y crea un registro de actividad.

3. El backend invoca al AI Layer vía gRPC (AnalyzeWriting RPC) con la referencia al archivo y el perfil pseudonimizado del estudiante.

4. La capa de IA procesa la imagen con un modelo de visión (Claude Sonnet multimodal) para transcribir el texto manuscrito.

5. La transcripción se envía al pipeline multi-agente (Sistema 3) que genera sugerencias socráticas contextualizadas al año escolar y el estado del Student KG.

6. El Assessment Agent evalúa coherencia y ortografía, generando métricas que se devuelven al backend junto con el feedback.

7. El backend persiste las métricas (coherencia, ortografía, vocabulario) y presenta al estudiante el feedback motivador. El docente ve la foto original, la transcripción, el feedback entregado y las métricas en su vista de corrección.

4.2 Historia B: Fluidez lectora

1. El docente asigna un párrafo de lectura desde el LMS (vía Deep Linking LTI).

2. El estudiante graba su lectura en voz alta desde la interfaz (Web Audio API).

3. El audio se sube al backend → S3/MinIO.

4. El AI Layer procesa el audio: transcripción automática (Whisper/equivalente), alineación forzada palabra por palabra con el texto de referencia, cálculo de WPM, detección de pausas excesivas y palabras omitidas/sustituidas.

5. El tutor socrático genera refuerzo positivo e indicaciones sobre puntos de mejora (pausas, puntuación, palabras específicas).

6. El panel docente muestra: completitud de la actividad por estudiante, WPM aproximado, alertas automáticas para estudiantes con dificultades significativas.

[PLACEHOLDER: Diagrama de flujo de datos: Historia A (escritura) e Historia B (lectura)]

4.3 Datos para investigación (ETL/ELT)

La arquitectura contempla un pipeline de datos desacoplado para que Ceibal pueda realizar investigaciones de aprendizaje:

- Eventos pedagógicos anonimizados se publican a una cola de mensajes (SQS/NATS).
- Un pipeline ELT los transforma y carga en un data warehouse (compatible con las herramientas de BI de Ceibal).
- Pseudonimización irreversible de datos personales antes de ingestar al warehouse.
- Retención y borrado alineados con políticas OWASP y privacidad por diseño.

5. Estrategia y Gestión de IA

5.1 Elección de modelos

Tarea	Modelo	Justificación
Transcripción de manuscritos / Tutor Socrático	Claude Sonnet (multimodal)	Capacidad nativa de visión para manuscritos infantiles, razonamiento complejo necesario para andamiaje socrático, soporte multiidioma (español nativo).
Guardrails (Pre y Post)	Claude Haiku	Latencia ultra-baja (<50ms), costo 10x menor que Sonnet; suficiente para clasificación binaria de contenido.
Assessment Agent	Claude Haiku	Evaluación estructurada (rubric-based) que no requiere razonamiento complejo.
Transcripción de audio	Whisper Large v3 (auto-alojado)	Precisión superior en español rioplatense/uruguayo, control total de costos, sin envío de audio infantil a terceros.
Generación de ejercicios (batch)	Claude Sonnet	Calidad narrativa alta para variaciones de ejercicios, ejecutado offline sin restricción de latencia.

La selección sigue el principio de mínimo modelo suficiente: cada tarea usa el modelo más pequeño (y económico) que cumple con el umbral de calidad requerido. Esto es crítico para la viabilidad económica a escala de cientos de miles de usuarios.

5.2 Estrategia de Prompt Engineering

La estrategia se basa en Ingeniería de Roles (Role Engineering) con system prompts estructurados:

- Cada agente tiene un system prompt versionado, firmado digitalmente y almacenado en repositorio privado.
- Los prompts del Tutor Socrático incluyen instrucciones explícitas: «NUNCA reveles la respuesta. Formula preguntas que guíen al estudiante a descubrirla.»
- El Student Knowledge Graph se inyecta como contexto estructurado (JSON) en cada llamada, no como texto libre. Esto evita el desbordamiento de tokens y permite al modelo calibrar con precisión.
- Marco CARE (metaprompts invisibles): cuando el sistema detecta peticiones transaccionales directas («dime la respuesta»), intercepta y fuerza andamiaje dinámico redirigiendo hacia la reflexión.
- Prompts contextualizados al año escolar: el vocabulario, la complejidad de las preguntas y el tono se ajustan dinámicamente según el grado (3.º-6.º) y los pesos del KG del estudiante.

5.3 Mecanismos anti-alucinación (Guardrails)

Los guardrails operan en tres niveles complementarios:

Nivel 1 — Pre-procesamiento: el Guardrail Pre filtra el input del estudiante antes de que llegue al tutor. Detecta: contenido inapropiado, intentos de prompt injection, solicitudes de respuestas directas.

Nivel 2 — Post-procesamiento: el Guardrail Post verifica cada token generado por el Tutor antes de ser renderizado. Bloquea: revelación accidental de respuestas, datos personales, información fáctica inventada.

Nivel 3 — Restricción de dominio: el KG-RAG actúa como fuente de verdad curricular. El tutor solo puede referenciar conceptos presentes en el grafo, eliminando la posibilidad de generar contenido fuera de programa.

La justificación pedagógica es doble: los guardrails protegen al niño de contenido dañino Y protegen el proceso de aprendizaje al impedir que la IA «regale» respuestas por su tendencia natural (RLHF helpfulness bias).

5.4 Control de costos a escala

Para soportar cientos de miles de usuarios con viabilidad económica:

Estrategia	Impacto estimado	Detalle
Caché semántico multi-nivel	Reducción 60-70% llamadas LLM	L1: LRU in-memory por worker. L2: hash exacto en Redis. L3: semantic cache (embeddings, sim ≥ 0.92).
Modelo mínimo suficiente	Costo 10x menor en guardrails	Haiku para clasificación, Sonnet solo para tutoría y visión.
Student KG vs. historial	Eliminación de context overflow	En lugar de enviar meses de chat, se envía JSON compacto del grafo. Reduce tokens de input drásticamente.
Whisper auto-alojado	Costo fijo vs. por-minuto	GPUs spot (T4/A10) para audio, con fallback a CPU. Evita costos por minuto de APIs de terceros.
Auto-pausing nocturno	25-30% reducción base	Componentes no críticos (dashboards, analítica) se pausan en horario inactivo.
Batch pre-generación	Latencia 0 en ejercicios	Sistema 1 genera ejercicios offline; el runtime solo selecciona, no genera.

6. Escalabilidad y Consideraciones Productivas

6.1 Infraestructura y contenerización

- Docker con imágenes base mínimas (distroless/alpine), usuario no-root.
- Diseño compatible con Kubernetes (Rancher) y HPA basado en métricas custom (latencia de inferencia, msg/s).
- Almacenamiento compatible con S3 (MinIO) para assets, audios y fotos.
- MySQL 8.0+ como base relacional principal (alineado al stack de Ceibal); Neo4j para grafos de conocimiento.
- Healthchecks en todos los servicios; diseño stateless para permitir múltiples réplicas.

6.2 Objetivos de rendimiento

Métrica	Objetivo	Justificación
Latencia E2E (tutoría)	≤ 200ms (P95)	Experiencia conversacional fluida.
Inferencia LLM (P95)	≤ 95ms	Tiempo de respuesta natural.
Throughput WebSocket @ 100k CCU	≥ 40k msg/s	Soporte para sesiones concurrentes a escala nacional.
Cache hit ratio (prompts)	≥ 90%	Minimización de costos LLM.
Cold boot / reconnección	≤ 2s	Consistencia tras fallo.

6.3 Observabilidad

- Logs por salida estándar, estructurados en JSON.
- Trazabilidad distribuida con OpenTelemetry: cada interacción genera un traceId único que conecta frontend → backend → AI layer.
- Dashboards por dominio (infraestructura, IA, UX) en Prometheus + Grafana + Loki.
- Alertas críticas automáticas: latencia E2E > 200ms, error rate LLM > 1%, throughput < umbral.

6.4 Seguridad y privacidad

- Cifrado en reposo (AES-256-GCM) y en tránsito (TLS 1.3 + mTLS interno).
- Gestión de secretos compatible con Vaultwarden.
- Pseudonimización obligatoria: la capa de IA nunca recibe nombres reales ni datos personales directos.
- Cumplimiento OWASP: validación de inputs, protección contra prompt injection, sanitización de outputs.
- Privacidad por diseño: logs de moderación con TTL de 30 días y borrado automático irreversible.
- DPIA (Data Protection Impact Assessment) requerido para cada feature que procese contenido generado por menores.

6.5 Calidad de código y DevOps

- Git-flow: ramas develop, testing, preprod, master. Versionado semántico.

- Pipeline CI/CD con validaciones de lint, type check, tests unitarios y seguridad estática (Trivy, Semgrep).
- Canary + blue/green deploys.
- Rollback automático si error rate > threshold en 5 minutos.

7. Extensiones Futuras

7.1 Modelado predictivo de estudiantes

Evolucionar el Knowledge Tracing estático hacia modelos predictivos (DKT/LSTM) que anticipen el estado cognitivo futuro del estudiante, permitan clasificar perfiles de aprendizaje y resuelvan el problema de cold-start para nuevos usuarios.

7.2 Evaluaciones orales asíncronas (Socratic Mind)

Un formato de evaluación donde la IA actúa como examinador conversacional por voz, requiriendo que el estudiante explique sus procedimientos y defienda conceptos abstractos. Virtualmente inmune al fraude académico: si el estudiante consulta otra IA, no podrá defender con fluidez los cuestionamientos de seguimiento.

7.3 Gamificación adaptativa

Evolución del sistema de XP/recompensas desde fórmulas fijas hacia variables de decisión co-optimizadas con la selección de ejercicios: bandits contextuales, multiplicadores derivados del KG, predicción de fatiga.

7.4 Dashboards directivos avanzados

Informes agregados con métricas comparativas entre grupos, escuelas y zonas. Exportación de datasets anonimizados para investigación. Análisis de tendencias longitudinales.

7.5 Soporte de contenido expandido

Extensión a otros ejes curriculares más allá de lectoescritura: matemáticas, ciencias, pensamiento computacional. Ejercicios con simuladores interactivos y desafíos de resolución en tres fases (identificación, planificación, ejecución).

8. Experiencia de Usuario

Las interfaces se diseñan aplicando heurísticas de usabilidad específicas para niños de 8-12 años:

- Mínima carga cognitiva: una acción principal por pantalla, lenguaje simple, iconografía clara.
- Refuerzo positivo siempre: el tono del tutor es motivador, incluso cuando señala áreas de mejora.
- Entrada multimodal natural: foto con la cámara del dispositivo, grabación de audio con un solo botón, chat conversacional.
- Feedback inmediato: indicadores visuales de progreso, animaciones de éxito.
- Interfaces diferenciadas por rol: el estudiante ve una experiencia lúdica; el docente ve una herramienta profesional de gestión.
- Alfabetización digital diversa: la solución no asume competencia técnica avanzada del estudiante ni del docente.